

한효정

Hyojung Han

AI Systems Engineer

hyojunguy@gmail.com · 서울시 송파구 잠실동

github.com/sylvanus4 · thakicloud.com/tech-blog



핵심 역량

- 2007년부터 공백 없이 19년째 컴퓨터 비전, 추천, 생성 AI, 엔터프라이즈 AI 플랫폼을 만들어 온 AI 시스템 엔지니어입니다.
- 현재 ThakiCloud에서 추론(Metis), 학습(Maxis), 에이전트 자동화(Paxis) 세 플랫폼의 제품 전략과 아키텍처를 설계하고 팀을 이끕니다.
- 생성 AI 콘텐츠 플랫폼을 직접 창업해 일본·대만·홍콩 3개 시장에서 유료 사용자 5만 명, 누적 매출 4억 원을 만든 경험이 있습니다.
- 한국어·영어·아랍어 3개 언어 기술 블로그를 운영하며 2,260편을 쓰고 608편을 공개했습니다. 동작하는 구현 사례 32건을 독립 연구로 축적했습니다.
- 모델부터 인프라, 제품까지 직접 만들어 본 경험을 바탕으로 방향을 정하고, 필요한 부분은 지금도 직접 구현합니다.

보유 기술

에이전트 하네스 · 오케스트레이션 (Paxis) 하네스 엔지니어링 · 루프 엔지니어링 · 그래프 엔지니어링 · MCP 툴 연동 · 스킴 라우팅 · 검색증강 · LangGraph · Human-in-the-Loop 승인 · 정책 · 감사 추적 · 결정론 검증 게이트 · 멀티에이전트 합의

학습 · 파인튜닝 · 종류 (Maxis) SFT · CPT · DPO · GRPO · GKD · LoRA · QLoRA · 지식 종류 · FSDP · DDP · TRL · Unsloth · MLflow · 평가셋 · 회귀 테스트

추론 · 서빙 · 압축 (Metis) vLLM · NVIDIA Dynamo · LMCache · Prefill-Decode 분리 · NVFP4 · W4A16 · LLM Compressor · MoE 압축 · 프루닝 · Scale-to-Zero · KServe · 모델 라우팅

음성 · 비전 · 생성 모델 VoxCPM2 TTS · Qwen3-TTS · Qwen3-ASR · 화자 분리(pyannote) · VLM 영상 이해 · Stable Diffusion · DreamBooth · GPT Image · Text-to-Video · EmbeddingGemma · AdaFace · ArcFace · OpenCV · ViT

플랫폼 · GPU 인프라 Kubernetes · Kueue · MultiKueue · ArgoCD · GitOps · Helm · Keycloak · SeaweedFS · CloudNativePG · NATS · Prometheus · Grafana · CUDA · Docker

언어 · 프레임워크 Python · Go (Fiber) · TypeScript · C++ · React 19 · Next.js · FastAPI · PyTorch · PostgreSQL · Redis

고전 ML · 최적화 LightGBM · CatBoost · XGBoost · scikit-learn · Google OR-Tools · Airflow · 선형계획 · 제약 최적화 · 시계열 · 랭킹

경력 사항

ThakiCloud AI 플랫폼 기획 · 설계 · 리딩 서울 역삼

2025.04 ~ 현재

추론 · 학습 · 에이전트 플랫폼 세 축을 기획하고 설계하며 팀을 이끌고 있습니다. 기술 블로그 발행 파이프라인도 함께 운영합니다.

AI 플랫폼 3종 기획 · 아키텍처 설계 · 리딩

- 추론(Metis) · 학습(Maxis) · 에이전트(Paxis) 세 축의 제품 방향과 기본 아키텍처를 설계하고, 실험 우선순위를 정해 개발팀을 리딩
- Kubernetes GPU 스케줄링 · 멀티테넌시 · GitOps 배포 체계의 설계 방향을 잡고 구축을 총괄

에이전트 빌더 사내 시스템 연동 (직접 구현)

- 에이전트 빌더를 사내 시스템과 연동해 실제 업무를 에이전트로 조립·실행하는 경로를 직접 설계하고 구현
- 모델 양자화(NVFP4 · W4A16)를 직접 담당해 서빙 가능 여부까지 검증한 뒤 배포 대상으로 확정

기술 블로그 운영과 다국어 발행 파이프라인

- 초안 생성부터 사실 검증, 번역, 배포까지 이어지는 발행 파이프라인을 구축해 2024년 5월부터 2,260편을 작성하고 608편(한국어 307 · 영어 301)을 공개 운영
- 11개 카테고리에 걸쳐 품질 게이트를 코드로 강제해 3개 언어를 동일 품질 기준으로 유지

2i Studio (창업) 창업자 경기 용인

2024.03 ~ 2025.04

생성 AI 콘텐츠 플랫폼을 직접 창업해 기획부터 개발, 운영까지 전 과정을 담당했습니다.

얼굴 기반 생성 AI 콘텐츠 플랫폼

- DreamBooth 파인튜닝 기반 동일인물성 보존 생성 파이프라인을 설계해 누적 매출 4억 원, 유료 결제 사용자 5만 명을 달성
- FastAPI · RabbitMQ 생성 큐와 Expo · Next.js 앱 · 웹을 직접 구현해 일본 · 대만 · 홍콩 3개 시장에 출시

Toss 시니어 머신러닝 엔지니어 서울

2021.01 ~ 2024.02

CDP 개인화, 생성 AI 도구, 얼굴 인증, 근무 스케줄링까지 여러 도메인을 넘나들며 머신러닝 시스템을 설계하고 구현했습니다.

고객 데이터 플랫폼과 개인화 예측

- 서비스별 · 유저별 CTR · CVR 예측 모델을 구축해 SQL 세그먼트 수작업을 확률 기반 자동화로 전환
- A/B 테스트 조기 종료 판단 모델을 별도로 설계해 테스트 기간을 75% 단축

디자이너용 그래픽 생성 도구 Tosst

- 토스 스타일 템플릿을 엮은 Stable Diffusion 프롬프트 엔진을 구축해 캐릭터 제작 주기를 수 주에서 2~3일로 단축
- 외주 비용 수천만 원을 절감하고 토스 블로그 · 웹 · 앱 전반의 그래픽 제작에 적용

UI 코드 생성기와 RAG 검색 시스템

- 사내 UI 시스템에 맞춰 LLaMA를 파인튜닝해 YAML 입력만으로 프로토타입 코드를 생성
- LangChain · ChromaDB 기반 자연어 검색을 붙여 프로토타입 제작 시간을 수 시간에서 수 분으로 단축

얼굴 결제와 스마트도어락 인증

- 3D 깊이 기반 위조 방지와 AdaFace · ArcFace 커스터마이징으로 실시간 얼굴 인증 정확도를 개선
- JNI로 안드로이드 · iOS 네이티브 모듈에 직접 연동해 카드 · 비밀번호 없는 결제 · 출입 인증을 구현

고객센터 근무 스케줄 자동 편성

- 근무 · 휴가 · 교대 제약을 선형계획으로 모델링하고 Google OR-Tools로 풀어 편성 시간을 2주에서 5분으로 단축
- 동일 엔진을 수천 명 규모 워크숍 숙소 배정에도 재사용해 확장성을 검증

삼성전자 시니어 소프트웨어 엔지니어 · ML 리서처 · 개발 매니저 수원

2011.09 ~ 2020.12

ML 플랫폼과 5G 네트워크 자동화, 음악 인식 엔진을 만들며 조직의 기술 방향에도 관여했습니다.

사내 클라우드 머신러닝 플랫폼

- Kubernetes 기반 ML 플랫폼을 설계해 모델 배포 리드타임을 수 일에서 수 시간으로 단축
- WaveNet · DeepVoice2 · SRGAN · CycleGAN · SSD를 자동 배포 체계에 엮어 여러 팀의 PoC를 실서비스로 전환

5G vRAN GPU 자동화와 통계 분석

- CUDA 기반 병렬 처리를 최적화하고 실시간 통계 시스템을 설계해 5G 초기 런칭의 병목 구간을 자동 탐지
- NVIDIA 본사와의 기술 워크숍을 직접 주관해 글로벌 협업 창구 역할을 수행

300만 곡 실시간 음악 인식 엔진

- Compact Sub-Fingerprint Hashing 기반 자체 오디오 지문 엔진을 설계해 외부 API 의존 없이 300만 곡 이상을 실시간 인식
- 고속 해시 인덱싱 구조와 안드로이드 앱을 직접 구현해 삼성전자 논문상 최종 후보에 선정

Daum 머신러닝 엔지니어 제주

2008.09 ~ 2011.08

사물 인식과 이미지 검색 시스템을 만들며 컴퓨터 비전 경력을 시작했습니다.

사물 인식과 이미지 검색 시스템

- Histogram 기반 Hamming Embedding과 LIS 인덱싱으로 700만 장 규모 실시간 이미지 매칭 시스템을 설계
- 이미지 해시 중복 제거 · 얼굴 검출 · 카테고리 분류기를 함께 구현해 쇼핑 검색 대표 이미지 추천 로직에 적용

비전 스타트업 소프트웨어 엔지니어 서울

2007.01 ~ 2008.08

영상 처리와 패턴 인식으로 커리어를 시작했습니다. 여기서 다룬 문제들이 이후 이미지 검색으로 이어졌습니다.

영상 처리 · 패턴 인식 모듈

- 카메라 입력에서 특징을 추출하고 매칭하는 비전 모듈을 C++로 구현
- 영상 전처리와 인식 정확도 개선을 반복하며 컴퓨터 비전 기본기를 축적

직접 구현한 시스템

비전, 신호 처리, 최적화, 추천처럼 제가 오래 다뤄 온 영역을 에이전트로 더 넓게 확장하며 직접 구현합니다. 무엇을 재야 답이 나오는지 이미 알기 때문에 논문을 읽는 자리에서 곧바로 실측 가능한 구현으로 넘어갑니다. 저장소 131개를 만들어 운영하며 그중 32건은 측정값이 붙은 완성 구현입니다.

최적화·스케줄링

- 근무표가 안 풀리는 이유를 제약 완화 트레이드오프로 정량화하는 인력 스케줄링 엔진
- 증원 없이 시프트 구조 재설계만으로 SLA를 끌어올린 인력 배치 최적화 엔진
- 이동거리와 연속 원정 일수를 함께 최소화하는 다목적 일정 최적화
- 배차 최적화로 동일 라이더 수에서 배달 처리량을 증대
- 배정·편성 문제 3건에서 실현 가능성을 감이 아닌 증명으로 확인하는 검증 엔진
- LLM 생성-수정 최적화 루프를 조합최적화 벤치마크 3개에 적용해 2승 1패로 검증

인프라·배포

- 복제본 3벌로는 못 잡는 데이터 부식(bit rot)을 온프레임 스토리지에서 실측
- 스토리지 검증 도구를 자사 인프라에 먼저 겨냥 결함을 스스로 찾아내는 진단 하네스
- 클라우드 대비 온프레임 전환의 손익분기점을 TCO로 계산
- 인터넷이 없는 폐쇄망 설비에도 AI 모델을 안전하게 전달하는 배포 경로 설계
- 테스트는 전부 통과했지만 실제 클라이언트 연동에서 1분 만에 죽는 결함을 재현·검증

데이터·추천

- 부서별로 흩어진 엑셀을 표준 ETL로 통합해 경영 현황 조회를 만나절에서 즉시로 단축
- 결품과 악성재고를 동시에 줄이는 수요예측 기반 재고 최적화
- 제안 골든타임을 놓치지 않는 영업 인텔리전스 레이더
- 인기순 대조군을 세워 추천 모델의 실제 개선폭을 재는 GPU 벤치마크 하네스
- 위치 정보를 넣어 도달 불가능한 매장 추천을 걸러내는 로컬 커머스 시맨틱 ID 인덱스

비전

- 검사원마다 다르던 판정 기준을 통일하는 24시간 제조 비전 검사 AI
- 이미지 분할 오류를 찾아 스스로 고치는 연구 도구 자동화 페루프
- GPU 서버 없이 소비자용 실리콘에서 영상 이해 AI 성능을 실측

에이전트·자동화 하네스

- 견적·발주 수기입력을 자동화해 담당자는 예외 건만 처리하는 문서 자동화
- 반복 문의는 AI가 처리하고 사람은 진짜 상담에 집중하는 AI 상담 에이전트
- 20년 베테랑의 노하우를 질문 한 번으로 꺼내는 RAG 지식 자산화
- 제품 정보만 넣으면 채널별 홍보영상과 온라인 존재감을 자동으로 만드는 마케팅 자동화
- "부산 출장 준비해줘" 한마디로 앱 여러 개를 대신 실행하는 대화형 에이전트 오케스트레이션
- 백지 도면에서 비판 가능한 초안까지 열 분 만에 도달하는 설계 자동화 페루프
- 스킬 1,600여 개를 BM25와 임베딩 하이브리드로 라우팅하는 에이전트 하네스
- 무인 스케줄 파이프라인 13종을 운영하며 실패를 회고로 되먹여 모델 등급을 자동 조정

신호·음향

- 무선망을 멈추는 원인 불명 전파를 실시간으로 지목하는 신호 지문 분석
- 여분의 스마트폰 한 대로 통행량을 세는 무설치 음향 센싱
- 전파도 빛도 못 쓰는 방에서 소리로 데이터를 넘기는 에어갭 음향 통신

제품·도구

- 파일을 서버로 보내지 않는 한글 문서 변환기를 웹과 데스크탑 앱으로 출시(MIT 공개, 무업로드를 검사 40개로 상시 검증)
- 모델이 내 GPU에 올라가는지와 자체 호스팅이 API보다 싼지를 브라우저에서 계산하는 도구

학력